# Otmane El Bourki

**Ingénieur IA** · LLM & RAG en production · IA agentique · Optimisation d'inférence · Cloud & MLOps · Évaluation

Carrières-sous-Poissy, Île-de-France, France · Autorisé à travailler en France

+33 7 75 73 57 51 • otmane.elbourki@gmail.com • linkedin.com/in/oelbourki • github.com/oelbourki • oelbourki.com

Ingénieur IA confirmé : **3 ans d'expérience professionnelle et indépendante** en systèmes LLM, RAG et agentiques (**4,5+ ans en IA/ML**, recherche incluse), couvrant retrieval, serving, optimisation d'inférence, orchestration, déploiement cloud et évaluation. Débit d'inférence LLM **multiplié par 3** pour **47 % de coût en moins**, systèmes multi-agents conçus pour la finance, et développement d'accélérateurs IA chez ALTEN ($\mathbf{A^3}$).

## Expérience professionnelle

### Ingénieur IA confirmé — $A^3$ (AI at ALTEN)
Depuis juin 2026
**ALTEN Group** — AI for Management System & Accelerators
Rabat, Maroc

- **Livraison produit : en ligne en 3 mois, 101 utilisateurs actifs.** Conception et déploiement d'une plateforme IA de recherche de références clients (React, FastAPI, pgvector, Azure) pour les commerciaux et directeurs d'ALTEN ; 1 103 recherches au lancement.
- **Qualité RAG : 80 % R@1, 90 % R@5, MRR 0,85.** Pipeline RAG (Mistral OCR et embeddings, repli sur OpenAI) avec un reranker LLM qui sélectionne les meilleures références clients et justifie chaque choix ; évaluation interne sur 100 questions.
- **Qualité pilotée par l'évaluation.** Framework d'évaluation (métriques de retrieval, contrôles du reranker), promotion de l'eval-driven development dans $A^3$, sensibilisation du Chief AI Office aux besoins de gouvernance IA.

### Ingénieur IA
Févr. 2026 – Juin 2026
**Indépendant** — R&D & Open Source
Paris, France

- **Open source : codibox sur PyPI.** Sandbox Python dans Docker (isolation par namespaces), outil d'exécution sécurisée de code généré par des agents pour LangGraph.
- **Automatisation multi-agents : recherche de 3 h à 15 min.** Conception d'une plateforme immobilière (LangChain deepagents, 6 sous-agents, 15+ outils sur mesure) pour l'estimation, le ROI et l'étude de marché.
- **GraphRAG pour la due diligence financière.** Neo4j avec retrieval hybride vectoriel/full-text sur un vaste corpus financier : Q&R LLM pour due diligence, conformité et risques.

### Ingénieur IA · (CDD)
Févr. 2025 – Févr. 2026
**Impactera** — Conseil financier (ESG & data intelligence)
Paris, France (télétravail)

- **Automatisation : rapports en 30 min au lieu d'une demi-journée.** Plateforme multi-agents à superviseur (LangGraph, 6 sous-agents, FastAPI, Docker) : RAG documentaire, accès API/NL-to-SQL, veille web et génération de rapports.
- **RAG fiable : réponses auditables.** Pipeline auto-correctif (Qdrant) avec semantic chunking, évaluation de la pertinence, détection d'hallucinations, citation des sources et repli automatique ; conçu à partir des besoins du CEO et des consultants financiers.
- **Routage multi-LLM : 5 fournisseurs, repli automatique.** Routage entre OpenAI, Anthropic, Gemini, Groq et Bedrock avec checkpointing asynchrone.
- **Orchestration d'API : agents générés à l'exécution.** Agent générant des agents outillés depuis des spécifications OpenAPI (Tagetik CPM, clients), sécurisé par OAuth.

### Founding AI Engineer · (CDD)
Juin 2023 – Juin 2024
**Tetricks** — Solutions IA pour l'hôtellerie (soutenu par l'École Polytechnique)
Télétravail

- **Optimisation d'inférence : débit ×3, coût −47 %.** Stack de serving vLLM avec quantification AWQ/GPTQ et batching dynamique, par rapport au serving de référence.
- **Vision-LLM : déployé sur GCP.** Pilotage de l'intégration (génération de descriptions de chambres) avec le CEO et l'équipe Dev ; financement d'innovation Bpifrance obtenu.
- **Fine-tuning métier : 12+ intentions en production.** Fine-tuning de Llama 2 sur données hôtelières (détection d'intentions), déployé dans la messagerie voyageurs.
- **RAG multimodal sur GCP.** Chatbot (Vertex AI + Cloud Run) avec pipeline d'ingestion validé par Pydantic et retrieval hybride vectoriel/lexical avec reranking.

### Assistant de recherche en ML
Janv. 2022 – Juin 2023
**Université Ibn Tofaïl** — Laboratoire de recherche
Kénitra, Maroc

- **RAG médical : Q&R clinique avec sources citées.** Chatbot (Meditron 7B, Qdrant, PubMedBERT) réduisant les hallucinations par un retrieval qui cite ses sources.
- **Classification de dialectes : 94,5 % de précision.** North, classifieur de dialectes nord-africains (scikit-learn + BERT fine-tuné) pour l'arabe et l'arabizi.
- **Vision par ordinateur : 90 % de précision moyenne (AP).** Benchmark d'architectures de pointe sur FER2013 ; +20 % de généralisation par augmentation et régularisation.

## Leadership & Engagement associatif

### Fondateur & Président
Oct. 2019 – Janv. 2022
**1337 AI** — Association éducative
Ben Guerir, Maroc

- **Communauté IA : 300 membres.** Création et animation, 2 bootcamps et 6 ateliers (Python, ML, IA générative).
- **Mentorat de hackathons (2023–2025).** Co-mentor à ThinkAI 2023 et HackAI 2024–25, avec des mentors Hugging Face et Mistral.

## Compétences techniques

**IA agentique**
LangGraph · LangChain · CrewAI · Google ADK · DSPy · MCP · Agentic RAG

**RAG & IA documentaire**
RAG · GraphRAG · Hybrid Search · Reranking · Qdrant · Neo4j · pgvector · Document AI / OCR · VLMs · Retrieval multimodal

**Ingénierie LLM**
vLLM · AWQ/GPTQ · LoRA/QLoRA · Optimisation d'inférence · Routage multi-LLM · Génération structurée · Fine-tuning

**Évaluation & Observabilité**
RAGAS · LangSmith · Arize Phoenix · LLM-as-Judge · Évaluation d'agents · OpenTelemetry · Prometheus · Grafana

**Systèmes IA, Cloud & MLOps**
Azure · GCP · AWS · Docker · Kubernetes · Terraform · CI/CD · Azure DevOps · MLflow · GitOps

**Sécurité & Gouvernance**
LLM Red-Teaming · Guardrails · Défense contre le prompt injection

**Programmation**
Python · FastAPI · Pydantic · SQL · C++ · CUDA · PyTorch

## Formation

**Expert en Architecture Informatique**
RNCP 7 · Architecture des données · École 42

**Master en Intelligence Artificielle**
Université Ibn Tofaïl, Kénitra, Maroc

**Licence en Informatique**
Université Ibn Tofaïl, Kénitra, Maroc

**Architecte des technologies numériques — Tronc commun**
École 1337, UM6P, Ben Guerir, Maroc

**Bac Sciences Mathématiques A, Maroc**

## Projets académiques

**Systèmes & IA accélérée** · École 42
Oct. 2024 – Févr. 2025

- Moteur d'algèbre linéaire C/C++ accéléré par **CUDA** (opérations matricielles, inverses, déterminants).
- **Inception of Things** : clusters **K3s**/K3D avec GitOps **ArgoCD** et CI/CD GitLab.

## Certifications

**GCP AI Infrastructure** — Google Cloud 2026
**GPU Programming** — Johns Hopkins 2026
**GenAI Winter School** — École Polytechnique 2024
**Red Teaming LLM Apps** — DeepLearning.AI 2025
**LangGraph** — LangChain 2025
**Advanced RAG** — DeepLearning.AI 2024
**Deep Learning Specialization** — DL.AI 2020

## Open Source & Projets

**codibox** — sandbox Python • PyPI
**Real Estate Deep Agents** — multi-agents
**AgenticDataAnalyst** — NL-to-Python

## Langues

**Arabe** (langue maternelle)
**Anglais** (capacité professionnelle complète)
**Français** (capacité professionnelle)